



南开大学
Nankai University

南 开 大 学

计 算 机 学 院

自然语言处理实验报告

文本分类实现

姓名：付子璇

学号：2313715

专业：计算机科学与技术

指导教师：曾庆锴

2026 年 10 月 5 日

目录

一、 实验要求	1
二、 Task1 与 Task2 的实验过程	1
(一) 数据预处理	1
1. 数据集分析	1
2. NYT 数据集划分	2
3. 分词及文本清洗	2
(二) 文本向量化	2
1. Task1-Bag of Words 实现	2
2. Task2-Word2Vec 实现	3
(三) Logistic Regression 分类器训练	4
(四) Logistic Regression 分类器测试	5
三、 Task3 的实验过程	5
(一) 数据集划分	5
(二) 标签映射与预训练模型加载	5
(三) BERT 分词与编码	6
(四) Fine-tuning 训练	6
(五) 测试集评测	6
四、 实验结果及分析	7
(一) 分类性能与结果分析	7
1. 六种方法的分类性能结果	7
2. 混淆矩阵	7
3. 六种方法性能总结	8
4. 两种 Bag of Words 文本表示方法的性能对比分析	8
5. 三种 Word2Vec 方法的性能对比分析	9
6. 三类文本表示方法的性能对比分析	11
(二) 训练过程与学习曲线分析	12
1. Logistic Regression 学习曲线图	12
2. 100-dimensional Word2Vec Model 训练损失图	14
3. Pre-trained BERT 训练曲线图	15

一、 实验要求

本次作业在同一份有标签新闻上比较不同文本表示方法的分类效果，要求如下：

1. 分类数据使用 NYT 新闻数据集 (`text`、`label`)，AG News 数据集仅含文本，用于训练 Word2Vec；NYT 按 8:1:1 划分为训练集、验证集、测试集，各方法共用同一划分，最终在 NYT 测试集上评价。
2. 评价指标为 Accuracy 与 Macro-F1。
3. Task1 使用 Binary Bag of Words 与 Word Frequency 两种 Bag of Words 表示，分类器为 Logistic Regression。
4. Task2 使用 100 维词向量：Pre-trained GloVe、在 AG News 上自训的 Word2Vec、在 NYT 训练集上自训的 Word2Vec；文档向量由有效词向量平均得到，分类器仍为 Logistic Regression。
5. Task3 对 google-bert/bert-base-uncased 做 Fine-tuning，最大序列长度 64，训练 3 个 epoch。

二、 Task1 与 Task2 的实验过程

对于 Task1 和 Task2，整体实验流程均为划分数据集、分词及文本清洗、将每篇新闻文本转换为分类器输入的文档向量、训练 Logistic Regression 分类模型、在 NYT 测试集上评价训练好的 Logistic Regression、保留测试集结果用于分析 badcase、绘制混淆矩阵和学习曲线。五种方法（Binary Bag of Words、Word Frequency、Pre-trained GloVe、Word2Vec Trained on AG News、Word2Vec Trained on NYT）仅在将新闻文本转换为分类器输入的文档向量这一环节的具体实现上有所不同，因此本章节对整体流程进行统一描述，相同步骤仅描述一次，并在（二）节中具体介绍五种方法在文本向量化环节的不同实现流程。

对于 Task3，其与 Task1、Task2 仅在数据集划分和测试集评测部分一致，其余流程存在一定差异，因此在下一章节即第三章中单独进行描述。

（一） 数据预处理

1. 数据集分析

本实验使用两个数据集，分别为 NYT 数据集、AG News 数据集。

NYT 数据集含 `text`、`label` 两列，共 11519 条有标签新闻，是分类任务的唯一数据：Task1、Task2、Task3 的训练、验证与测试均来自该数据集，Accuracy 与 Macro-F1 也只在数据集划分出的验证集、测试集上计算。标签为三类，类别严重不平衡，Sports 约占 75%，如表1所示。按词切分统计原始正文长度，最短 38、中位数 768、均值 730.4、最长 5977，超过 64 个 token 的样本占 99.88%，新闻篇幅整体较长。

AG News 数据集仅含 `text` 列，共 90000 条，无类别标签。该数据集只作为 Task2 中 Word2Vec-AG News 的无标注训练语料。篇幅明显短于 NYT 数据集，按空白分词的中位数约为 39 词。

类别	样本数量	占比
Sports	8639	75.00%
Politics	1451	12.60%
Business	1429	12.41%
总计	11519	100.00%

表 1: NYT 数据集类别分布

2. NYT 数据集划分

本实验首先对 NYT 数据集进行数据划分, 该数据划分的流程与代码由 Task 1/2/3 共用。在划分过程中设置固定随机种子 `random_state=42`, 并在默认打乱的前提下按类别标签 `label` 做分层随机划分。首先将数据集按照 80% 和 20% 的比例划分为训练集和临时集, 随后将临时集进一步均分为验证集和测试集。目标比例为 80%、10%、10%, 但因总样本数为 11519, 不能整除, 实际划分结果如表2所示, 分层抽样使三个子集类别比例与总体几乎一致。

数据集	样本数量	数据集占比	类别分布
训练集	9215	79.998%	Sports: 75.00%, Politics: 12.60%, Business: 12.40%
验证集	1152	10.001%	Sports: 75.00%, Politics: 12.59%, Business: 12.41%
测试集	1152	10.001%	Sports: 75.00%, Politics: 12.59%, Business: 12.41%
总计	11519	100.00%	-

表 2: NYT 数据集划分及类别分布

3. 分词及文本清洗

在 Task1 和 Task2 中, 对训练集、验证集和测试集采用相同的分词与文本清洗流程。首先使用 `nltk` 中的 `word_tokenize` 方法对原始文本进行分词, 在该过程中, 单词、数字串以及标点会被分别识别为独立 `token`; 并将所有 `Token` 统一转换为小写; 随后依次进行文本清洗, 去除停用词、完全由标点符号组成的 `Token`, 以及不包含任何英文字母的 `Token`, 从而过滤纯标点、纯数字等无效词项, 保留经过清洗后的有效 `Token` 序列。

(二) 文本向量化

1. Task1-Bag of Words 实现

(1) 构建词表

本实验**仅使用训练集构建词表**, 来避免验证集和测试集的信息泄露。首先遍历训练集中每篇文档经过预处理后的 `Token` 序列, 并去除重复词项, 将所有出现过的不同词项加入词表 `V`, 最终构建出的**词表大小 $|V|$ 为 121878**; 随后将词表按字典序排序后转为列表, 再为每个词分配整数下标, 最终构建词项到索引的映射关系。

(2) Binary Bag of Words

基于构建完的词表, 使用 Binary Bag of Words 方法将文本转换为特征向量。对于文档 d 和词表 V , 构造维度为 $|V| = 121878$ 的向量 $\mathbf{x}_d$, 若词表 V 中的词项 w_i 在文档中出现, 则

对应位置取 1, 否则取 0, 并且不在 V 中的词不进入向量, 即

$$x_{d,i} = \begin{cases} 1, & w_i \in d, \\ 0, & w_i \notin d. \end{cases}$$

按照上述方式将训练集、验证集和测试集分别转换为大小为样本数 $\times |V|$ 的 Binary BoW 特征矩阵, 并进一步转换为稀疏矩阵, 作为 Logistic Regression 分类器的输入。

(3) Word Frequency

基于构建完的词表, 使用 Word Frequency 将文本转换为特征向量。对于文档 d 和词表 V , 构造维度为 $|V| = 121878$ 的向量 $\mathbf{x}_d$, 其中 $x_{d,i}$ 表示词表中的词项 w_i 在文档 d 中出现的次数, 即

$$x_{d,i} = \text{count}(w_i, d).$$

按照上述方式将训练集、验证集和测试集转换为大小为样本数 $\times |V|$ 的词频特征矩阵, 并进一步转换为稀疏矩阵, 作为 Logistic Regression 分类器的输入。

2. Task2-Word2Vec 实现

(1) Pre-trained GloVe

首先加载从<http://nlp.stanford.edu/data/glove.6B.zip>中下载得到的预训练的 **100 维 GloVe 词向量**, 建立从词语到向量的映射表。对于经过分词和清洗后的每篇新闻, 仅保留能够在 GloVe 词表中找到对应词向量的有效单词, **不在词表中的词直接跳过**。对于一个单词 w_i , 其对应的 GloVe 词向量记为 $e(w_i) \in \mathbb{R}^{100}$ 。对于一篇文档 d , 设其有效 token 序列为 $w_1, w_2, \dots, w_n$ (n 为有效 token 次数, 同一词出现多次则计多次), 对应词向量为 $e(w_1), e(w_2), \dots, e(w_n)$, **采用词向量平均池化将所有词向量聚合为长度 100 的文档向量**:

$$e(d) = \frac{1}{n} \sum_{i=1}^n e(w_i), \quad e(d) \in \mathbb{R}^{100}.$$

如果一篇文档中没有任何单词能够匹配 GloVe 词表, 则将其文档向量设置为 100 维全零向量。最后, 对训练集、验证集和测试集中的每篇新闻分别进行上述处理, 得到对应的文档向量, 并分别构成 X_{train} 、 X_{val} 和 X_{test} , 形状大小为各自的样本数 $\times 100$, 作为 Logistic Regression 分类器的输入。

(2) Word2Vec Trained on AG News

首先使用 AG News 数据集的新闻文本训练 Word2Vec 词向量: 对 AG News 中的每篇新闻进行与 NYT 数据集相同的分词与文本清洗处理, 得到由有效单词组成的词序列, 并将其作为 Word2Vec 的训练语料。具体地, 设置词向量维度为 100, 窗口大小设置为 5, 仅保留在训练语料中出现次数不少于 5 次的单词, 训练轮数设置为 5。Word2Vec 通过利用词语的局部上下文关系学习词向量, 使具有相似上下文的词获得较为相近的向量表示。训练完成后得到由单词到 100 维词向量的映射表。

为观察 Word2Vec 的训练过程, 在代码中通过回调函数记录每个 epoch 的训练损失。由于 gensim 返回的是累计损失, 因此第 t 个 epoch 的实际损失计算为当前累计损失与上一 epoch 累计损失之差, 即

$$L_t = L_t^{\text{cum}} - L_{t-1}^{\text{cum}},$$

其中 L_t^{cum} 表示第 t 个 epoch 结束时的累计训练损失。

基于 AG News 的 100-dimensional Word2Vec Model 训练完成后，对于 NYT 数据集中的每篇新闻，仅保留能够在训练得到的 Word2Vec 词表中找到对应词向量的有效单词，**不在词表中的词直接跳过**。对于一篇文档 d ，设其有效 token 序列为 $w_1, w_2, \dots, w_n$ (n 为有效 token 次数)，对应词向量为 $e(w_1), e(w_2), \dots, e(w_n)$ ，**通过词向量平均池化得到固定 100 维的文档向量**：

$$e(d) = \frac{1}{n} \sum_{i=1}^n e(w_i), \quad e(d) \in \mathbb{R}^{100}.$$

如果一篇文档中没有任何单词能够匹配训练得到的 Word2Vec 词表，则将其文档向量设置为 100 维全零向量。最后，对 NYT 数据集的训练集、验证集和测试集分别进行上述处理，得到 X_{train} 、 X_{val} 和 X_{test} ，形状大小为各自的样本数 $\times 100$ ，作为后续 Logistic Regression 分类器的输入。

(3) Word2Vec Trained on NYT

首先**使用 NYT 的训练集新闻文本训练 100-dimensional Word2Vec Model**：将 NYT 训练集进行分词和文本清洗后得到的词序列作为 Word2Vec 的训练语料。与 Word2Vec Trained on AG News 方法相同，**设置词向量维度为 100**、窗口大小为 5、训练轮数为 5，并记录每个 epoch 的训练损失。

用 NYT 训练集训练完成后，用得到的 100-dimensional Word2Vec Model 分别对 NYT 训练集、验证集和测试集中的新闻进行文档向量表示。对于每篇新闻，仅保留能够在训练得到的 Word2Vec 词表中找到对应词向量的有效单词，**不在词表中的词直接跳过**。对于一篇文档 d ，设其有效 token 序列为 $w_1, w_2, \dots, w_n$ ，对应词向量为 $e(w_1), e(w_2), \dots, e(w_n)$ ，**通过词向量平均池化得到固定 100 维的文档向量**：

$$e(d) = \frac{1}{n} \sum_{i=1}^n e(w_i), \quad e(d) \in \mathbb{R}^{100}.$$

如果一篇文档中没有任何单词能够匹配训练得到的 Word2Vec 词表，则将其文档向量设置为 100 维全零向量。最终，分别得到 NYT 训练集、验证集和测试集的文档向量矩阵 X_{train} 、 X_{val} 和 X_{test} ，形状大小为各自的样本数 $\times 100$ ，作为 Logistic Regression 分类器的输入。

(三) Logistic Regression 分类器训练

采用 Logistic Regression 作为文本分类模型，主要参数设置如表3所示，仅使用训练集进行模型拟合，并在验证集上进行正则化强度参数 C 的调优，其候选值为 0.01, 0.1, 1, 10, 100。针对每个 C 值分别训练模型，并在验证集上计算 Accuracy 和 Macro-F1，公式如下。以验证集 Macro-F1 作为模型选择依据，最终选择 Macro-F1 最高对应的 C 值及其模型作为最终模型，用于测试集评价。

$$\text{Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(y_i = \hat{y}_i)$$

其中， N 表示样本总数， y_i 和 $\hat{y}_i$ 分别表示第 i 个样本的真实标签和模型预测标签， $\mathbb{I}(\cdot)$ 为指示函数。

$$\text{Macro-F1} = \frac{1}{K} \sum_{k=1}^K \frac{2P_k R_k}{P_k + R_k}$$

其中, K 表示类别数量, P_k 表示第 k 个类别的精确率 $P_k = \frac{TP_k}{TP_k + FP_k}$, R_k 表示第 k 个类别的召回率 $R_k = \frac{TP_k}{TP_k + FN_k}$ 。

参数	设置值
正则化方式	L2 正则化
正则化强度倒数 C	{0.01, 0.1, 1, 10, 100}
类别加权	不使用类别加权
最大迭代次数	1000
优化器	saga
随机种子	42

表 3: 逻辑回归模型主要参数设置

上述主要设置的选择原因如下: C 在验证集上按 Macro-F1 选取, 使五种表示共用同一套调参方式。不使用类别加权, 是为了让差别主要来自文本表示而非分类器对少数类的再加权。随机种子固定为 42 以便复现。优化器最初采用 liblinear, 但当前 sklearn 中该求解器不支持三类及以上的多分类, 直接拟合会报错, 因此改为支持多分类且可用于稀疏特征的 saga。sklearn 默认最大迭代次数为 100, 对本实验中的 saga 容易迭代不足, 因此将最大迭代次数提高到 1000。

(四) Logistic Regression 分类器测试

使用验证集上 Macro-F1 最优的 Logistic Regression 模型对测试集进行最终评测。首先将测试集标签提取为真实标签, 并将已经得到的测试集文档向量作为模型输入: Task1 的 Binary Bag of Words 与 Word Frequency 为词袋稀疏矩阵, Task2 的 Pre-trained GloVe 与两套 Word2Vec 为 100 维稠密向量。随后利用训练完成的最优模型对测试集进行预测, 得到预测标签。最后分别计算测试集上的 Accuracy 和 Macro-F1, 作为模型最终的分类性能指标。除此之外, 在测试集上保存模型的预测结果, 包括文本、真实标签和预测标签, 用于后续错误案例分析; 同时绘制并保存混淆矩阵。此外, 在固定最优超参数 C 的条件下, 按照 20%、40%、60%、80% 和 100% 的训练数据规模重新训练 Logistic Regression, 分别计算训练集和验证集的 Macro-F1, 并绘制学习曲线, 以分析模型性能随训练数据规模变化的趋势。

三、 Task3 的实验过程

(一) 数据集划分

本部分采用与 Task1、Task2 完全相同的 NYT 数据划分, 此处不再展开。

(二) 标签映射与预训练模型加载

由于 BERT 分类模型前向输出的是各类别的预测分数, 预测时再通过 argmax 得到类别编号, 因此首先对 NYT 训练集中的类别标签按字典序编号, 建立类别名称与数字编号之间的双向映射, 其中 business、politics、sports 分别对应 0、1、2。随后设置随机种子为 42, 加载**预训练模型 google-bert/bert-base-uncased** 及其配套分词器 BertTokenizer。在预训练 BERT 的基础上增加一个三分类头, 使模型输出三类对应的预测分数, 并通过 label2id 和 id2label 完成类别标签与模型输出编号之间的对应, 得到 BertForSequenceClassification。BERT 编码器参数来自预训练权重, 分类头随机初始化, 随后与编码器一并微调, 模型的总参数数量为 109484547。

(三) BERT 分词与编码

本部分直接对原始新闻文本使用 BERT 配套分词器编码，不去除停用词、标点和数字。设置最大序列长度为 64，对超过最大长度的序列进行截断，截断方式为保留序列开头、从尾部截去超出部分，不足的部分填充至 64，并返回 PyTorch 张量。对训练集、验证集和测试集分别进行分词与编码，将原始文本转换为模型所需的 Token ID 序列 `input_ids`，其形状分别为 (9215, 64)、(1152, 64) 和 (1152, 64)。接着将编码结果与数字标签封装为 `NYTDataset`。

编码完成后，在模型前向计算过程中，编码后的 Token 序列输入 BERT 编码器，取最后一层的 [CLS] 隐向量，经线性变换再经 Tanh 激活得到句向量，再输入三分类头得到三个类别对应的预测分数。

(四) Fine-tuning 训练

在 Fine-tuning 阶段，首先定义模型评估函数，根据模型输出的各类别预测分数取最大值对应的类别作为预测结果，并计算 Accuracy 和 Macro-F1 作为评价指标。随后使用训练集对预训练 BERT 进行 Fine-tuning，使用 HuggingFace Trainer，在每个 epoch 结束后使用验证集进行评估，同时记录训练损失以及验证集 Accuracy 和 Macro-F1，保存策略为不保存中间检查点，最终使用第 3 个 epoch 结束后的模型。具体的 Fine-tuning 参数设置如表4所示。训练完成后，根据记录的训练损失和验证集评价指标绘制训练曲线。

参数	设置值
预训练模型	google-bert/bert-base-uncased
最大序列长度	64
训练轮数	3
训练批大小	8
验证批大小	16
学习率	2×10^{-5}
权重衰减	0.01
优化器	AdamW
随机种子	42

表 4: BERT Fine-tuning 主要参数设置

(五) 测试集评测

模型 Fine-tuning 完成后，首先在验证集上进行评估，获取最后一个 epoch 对应的验证集评价结果。随后使用训练完成的 BERT 模型对 NYT 测试集进行预测，计算测试集 Accuracy 和 Macro-F1，作为本方法的最终分类性能指标。为便于后续分析，与 Task1、Task2 相同，将测试集原始文本、真实类别和预测类别对应保存为 CSV 文件，绘制混淆矩阵。

四、实验结果及分析

(一) 分类性能与结果分析

1. 六种方法的分类性能结果

方法	验证集 Accuracy	验证集 Macro-F1	测试集 Accuracy	测试集 Macro-F1
Binary Bag of Words($C=1.0$)	0.98264	0.95759	0.99219	0.98009
Word Frequency($C=0.01$)	0.98177	0.95966	0.99045	0.97647
Pre-trained GloVe($C=1.0$)	0.97830	0.95119	0.98611	0.96693
Word2Vec-AG News($C=1.0$)	0.97483	0.94270	0.98351	0.96091
Word2Vec-NYT($C=1.0$)	0.98003	0.95468	0.98524	0.96255
Pre-trained BERT	0.97830	0.95180	0.98264	0.96335

表 5: 六种方法的分类性能（注：前五种方法的 C 为通过验证集选择的最优正则化参数，表中指标均对应该 C ；Pre-trained BERT 的验证集指标为三轮训练结束后的最终模型在验证集上的评测结果。）

2. 混淆矩阵




图 1: Binary Bag of Words 测试集混淆矩阵




图 2: Word Frequency 测试集混淆矩阵




图 3: Pre-trained GloVe 测试集混淆矩阵




图 4: Word2Vec-AG News 测试集混淆矩阵




图 5: Word2Vec-NYT 测试集混淆矩阵




图 6: Pre-trained BERT 测试集混淆矩阵

3. 六种方法性能总结

从表5中的测试集指标来看, 六种方法的 Accuracy 均在 0.98 以上, 说明整体分类正确率很高。Macro-F1 均低于对应的 Accuracy, 表明三类表现并不均衡: 多数类 Sports 对 Accuracy 贡献更大, 少数类上的错误会被 Macro-F1 反映出来。在 Accuracy 方面, Binary Bag of Words 表现最好, 其次依次为 Word Frequency、Pre-trained GloVe、Word2Vec-NYT、Word2Vec-AG News 和 Pre-trained BERT。在 Macro-F1 方面, Binary Bag of Words 同样表现最好, 其次依次为 Word Frequency、Pre-trained GloVe、Pre-trained BERT、Word2Vec-NYT 和 Word2Vec-AG News。

4. 两种 Bag of Words 文本表示方法的性能对比分析

由表5可知, Binary Bag of Words 方法在测试集上的 Accuracy、Macro-F1 值均高于 Word Frequency 方法, 说明在本实验的新闻分类任务中 **Binary Bag of Words 方法表现更优**。

通过对保留的测试集预测结果进行统计得到, 在测试集的 1152 篇新闻中, Binary Bag of Words 与 Word Frequency 共有 1140 篇预测结果一致且均正确, 8 篇预测结果一致但均错误; 两种特征的预测结果仅有 4 篇存在差异, 其中 Binary Bag of Words 独立预测错误 1 篇, Word Frequency 独立预测错误 3 篇。

观察图1和图2中的 Binary Bag of Words、Word Frequency 的混淆矩阵，从保留的测试集预测结果中筛选出了 Task1 两类方法各自独有的 Badcase，如表6所示。四篇差异样本中，三篇是 Business 与 Politics 的交叉话题，一篇是 Sports 被词频误判为 Business；这些新闻均同时包含财政、预算、利率等商务词，以及国会、党派或奥运等各自的类别指示词。

文章主题	真实类别	Binary BoW 预测	词频预测	错误模型
美国债务上限与政府财政危机	business	politics	business	Binary BoW
Fix the Debt 的减赤倡议与利益关联	politics	politics	business	Word Frequency
参议院讨论学生贷款利率	politics	politics	business	Word Frequency
里约奥运组委会申请政府 7 亿美元运营费	sports	sports	business	Word Frequency

表 6: Binary Bag of Words (Binary BoW) 与 Word Frequency (词频) 的差异性 Bad Case

表6中的四篇差异性 Bad Case 主要出现在同时包含多个类别词汇的新闻中。仅 Binary BoW 出错的一篇真实类别为 Business, 被误判为 Politics: 文中既有反复出现的 treasury、debt、budget 等商务词，也有 congress、republican、partisan 等政治词，属于 Politics 与 Business 类别特征较为接近的情况。仅 Word Frequency 出错的三篇真实类别分别为 Politics、Politics 和 Sports, 均被误判为 Business；其中前两篇同样属于 Politics 与 Business 类别特征相近，而里约奥运一篇真实类别为 Sports，但以财政拨款为主要内容，较多的 budget、fund 等商务词使词频表示更容易偏向 Business，说明其对这类特殊表述的区分能力有限。可以看出，当一篇新闻同时具有多个类别的词汇特征时，两种方法更容易产生不同的预测结果。

造成差异的主要原因是两种特征对词频信息的表示不同。Binary BoW 只记录词是否出现，因此对少量主题指示词较敏感；Word Frequency 则保留词的出现次数，容易受到高频财政、预算等共享词的影响。Word Frequency 的最优 $C = 0.01$ 、Binary 的最优 $C = 1.0$ ，也与 Word Frequency 各维数值更大、更需更强正则相一致。对于本实验的 NYT 三分类任务，从实验结果来看，类别区分更多依赖主题指示词，因此 Binary Bag of Words 整体表现更好。

5. 三种 Word2Vec 方法的性能对比分析

由表5可知，在测试集 Accuracy 与 Macro-F1 上，Pre-trained GloVe 高于 Word2Vec-NYT，Word2Vec-AG News 最低。说明在本实验的新闻分类任务中 **Pre-trained GloVe 表现最优**，Word2Vec-NYT 次之，Word2Vec-AG News 表现最差。

通过对保留的测试集预测结果进行统计得到，在测试集的 1152 篇新闻中，Pre-trained GloVe、Word2Vec-AG News 与 Word2Vec-NYT 共有 1127 篇预测结果一致且均正确，9 篇预测结果一致且均错误。除去这 9 篇三者都错的样本后，Pre-trained GloVe 另错 7 篇，Word2Vec-NYT 另错 8 篇，Word2Vec-AG News 另错 10 篇。

接下来从 Pre-trained GloVe 与自训 Word2Vec 对比、两个自训 Word2Vec 对比的角度进行分析。

(1) Pre-trained GloVe 与自训 Word2Vec 的性能对比分析

在本实验的分类任务中，从测试集的两项指标来看，Pre-trained GloVe 方法的性能要优于两个自训 Word2Vec 方法。

对照图3、图4和图5中的混淆矩阵可知，三种方法在多数类 Sports 上接近，Pre-trained GloVe 与 Word2Vec-AG News 的 Sports 误判结构相同，与 NYT 测试集更近的 Word2Vec-NYT 在 Sports 上略好，说明总体差距不是 Sports 拉开的。真正差在少数类 Business 与 Politics

的互相混淆：Word2Vec-AG News 更易将 Politics 误判为 Business，而 Word2Vec-NYT 更易将 Business 误判为 Politics。并且对比三张混淆矩阵可见，Pre-trained GloVe 在 Business 和 Politics 上分别与 Word2Vec-AG News 和 Word2Vec-NYT 的优势侧一致，因此整体表现最好。

从测试集中进一步筛出两类对照样本：Pre-trained GloVe 预测正确而两个自训 Word2Vec 同时预测错误，以及 Pre-trained GloVe 预测错误而两个自训 Word2Vec 同时预测正确，如表7所示。

文章主题	真实类别	GloVe 预测	自训 Word2Vec 预测	错误模型
国会报告批评政府向违规企业发包	business	business	politics	自训 Word2Vec
Healthcare.gov 故障是否遭网络攻击	politics	politics	business	自训 Word2Vec
沃尔玛承诺雇佣退伍军人	politics	politics	business	自训 Word2Vec
瑞典咖啡文化与职业足球生活	sports	business	sports	Pre-trained GloVe

表 7: Pre-trained GloVe 与两个自训 Word2Vec 的差异性 Bad Case

表7进一步说明了差异所在：前三篇均为商业与政治交叉的文本，属于类别相近导致的政商混淆，两个自训 Word2Vec 都将 Business 与 Politics 混淆，而 Pre-trained GloVe 均能正确分类，体现了通用向量相对自训向量的优势；Pre-trained GloVe 唯一误判的一篇为 Sports，属于以生活随笔形式呈现的体育新闻，足球信息较少且靠后，平均池化难以突出相关信息，因此 Pre-trained GloVe 将其判为 Business。这说明 Pre-trained GloVe 并非在所有类别上都优于自训 Word2Vec，Sports 上自训 Word2Vec 仍可能表现更好。

三种方法均采用 100 维平均池化和 $C = 1.0$ 的 Logistic Regression，差别仅在词向量来源。Pre-trained GloVe 来自更大规模的通用语料，对国会、合同、医保、零售招聘等开放领域词汇的表示更稳定；AG 栏目与 NYT 不同，政策、政务类表述容易被拉向商务类；NYT 自训模型虽与测试数据同域，但训练数据仅来自训练集且规模有限，政商共用词汇仍容易在向量空间中靠拢。平均池化会将一篇文本中的不同类型词汇混合成一个文档向量，当词向量对政商区分不足时，分类器也更难将两类切分开。两个自训模型中，同域的 Word2Vec-NYT 仍优于异域的 Word2Vec-AG News，但领域接近 NYT 并不能单独解释 Pre-trained GloVe 仍优于 NYT 自训模型。

Pre-trained GloVe 整体表现更好，与自训 Word2Vec 的差距主要体现在 Business–Politics 交叉新闻上。Pre-trained GloVe 预训练语料覆盖面更广，在目标领域数据有限、类别边界涉及及开放领域词汇时更有优势；自训 Word2Vec 则更依赖训练语料与目标领域的匹配程度和规模。

(2) 两个自训 Word2Vec 的性能对比分析

在本实验的分类任务中，从测试集的两项指标来看，Word2Vec Trained on NYT 方法的性能要优于 Word2Vec Trained on AG News 方法。

对照图4和图5中的混淆矩阵可知，两种方法在多数类 Sports 上接近，与测试集同域的 Word2Vec-NYT 在 Sports 上略好。真正差距仍是在少数类 Business 与 Politics 的互相混淆：Word2Vec-AG News 更易将 Politics 误判为 Business，而 Word2Vec-NYT 更易将 Business 误判为 Politics。

从测试集中进一步筛出两类对照样本：Word2Vec-AG News 预测正确而 Word2Vec-NYT 预测错误，以及 Word2Vec-AG News 预测错误而 Word2Vec-NYT 预测正确，如表8所示。

文章主题	真实类别	AG News 预测	NYT 预测	错误模型
快餐工人争取 15 美元时薪的全国罢工	business	business	politics	Word2Vec-NYT
沃尔玛将医保扩至员工同性伴侣	business	business	politics	Word2Vec-NYT
法院支持用工强制放弃集体诉讼	business	business	politics	Word2Vec-NYT
最高法院审理 EPA 温室气体管制	politics	politics	business	Word2Vec-NYT
中途岛发现二战战机残骸	politics	politics	business	Word2Vec-NYT
Fix the Debt 的减赤倡议与利益关联	politics	business	politics	Word2Vec-AG News
枪械厂商对经销监管责任的证词	politics	business	politics	Word2Vec-AG News
蒙大拿精酿酒馆与立法之争	politics	business	politics	Word2Vec-AG News
国土安全部研发人群人脸识别	politics	business	politics	Word2Vec-AG News
马丁父母与业主协会达成和解	politics	sports	politics	Word2Vec-AG News
橄榄球名将网络女友骗局	sports	politics	sports	Word2Vec-AG News
伦敦奥运经济效益超出公共投入	sports	business	sports	Word2Vec-AG News

表 8: Word2Vec-AG News 与 Word2Vec-NYT 的差异性 Bad Case

表8进一步说明了差异：Word2Vec-NYT 的五个错误样本均涉及商业与政治交叉内容，其中三篇 Business 被误判为 Politics，两篇 Politics 被误判为 Business；Word2Vec-AG News 的七个错误样本中，多数 Politics 被误判为 Business，另有两篇 Sports 和一篇 Politics 被误判为其他类别。多数错例属于 Politics 与 Business 类别相近的情况，而女友骗局、伦敦奥运经济、马丁案则分别是 Sports 写成舆论或投资、案件写成赛事，平均词向量对这类写法的表示不足。因此，同域向量具有一定优势，但 Word2Vec-NYT 对带有政策、诉讼色彩的 Business 仍可能产生误判。

两种方法的差别仅在词向量的训练语料。Word2Vec-AG News 来自与 NYT 不同的 AG 新闻，政策、政务和劳资类表述容易被拉向 Business，奥运经济效益、精酿产销等内容也更接近其商务语料；Word2Vec-NYT 与测试数据同域，对国会、最高法院、劳资政治等词汇更敏感，因此更容易区分政务和体育文本，但也可能将带有运动、医保政策、劳动诉讼等内容的商务新闻误判为 Politics。两个自训模型的表现与领域匹配程度一致：同域的 Word2Vec-NYT 优于异域的 Word2Vec-AG News。

Word2Vec-NYT 整体表现更好，与 Word2Vec-AG News 的差距主要体现在 Politics 被异域向量拉向 Business、以及少量 Sports 误判上。就方法特点而言，自训 Word2Vec 更依赖训练语料与目标领域一致，适配同域场景。

6. 三类文本表示方法的性能对比分析

由表5可知，三类表示在测试集上的表现有所不同。Bag of Words (Binary Bag of Words, Word Frequency) 的 Accuracy 和 Macro-F1 均最高；Word2Vec (Pre-trained GloVe, Word2Vec-NYT, Word2Vec-AG News) 整体居中，其中 Pre-trained GloVe 最好、Word2Vec-AG News 最差；Pre-trained Neural Models (Pre-trained BERT) 的 Accuracy 为六种方法中最低，Macro-F1 高于两个自训 Word2Vec、低于 Pre-trained GloVe。测试集中 Sports 占 75%，三类均存在类别不平衡，Accuracy 更容易受到多数类影响，而少数类 Business、Politics 的分类效果在 Macro-F1 中体现得更明显。

对照图1至图6，三类表示的错误结构也有所不同。Bag of Words 强在主题指示词明显的新闻：Sports 几乎全部正确，总错误最少，政商交叉文本的错误也少于后两类。其原因是高维稀疏特征直接保留了任务词表中的栏目用词，对“是否出现某类词”较为敏感。其弱点在于难以处理

一词多类、共享商务词频较高的情况，且不建模词序和上下文，因此仍会在债务上限、减赤、贷款利率等 Politics-Business 相近文本上出错，里约奥运这类以拨款为主题的 Sports 新闻也可能因商务词汇较多而被误判。

在 Word2Vec 中，Pre-trained GloVe 凭借大规模通用语料，在开放领域词汇上的表示更稳定；Word2Vec-NYT 与测试数据同域，Sports 表现较好。其弱点在于维度较低，且平均池化后会将文本中的政商词汇压缩到同一个向量中，面对相近主题时难以划分类别边界：错误明显多于词袋，且主要集中在 Business 与 Politics 之间。Word2Vec-AG News 与 NYT 的栏目领域不同，Politics 更容易被判为 Business；Word2Vec-NYT 对带有政策、诉讼色彩的 Business 仍容易判为 Politics。瑞典咖啡、伦敦奥运经济、女友骗局等样本则属于写法偏离栏目主题的情况，平均词向量的表示能力有限。

Pre-trained BERT 强在能够结合上下文生成句向量，在少数类 Business 上的表现好于两个自训 Word2Vec，因此 Macro-F1 高于 Word2Vec-NYT。其弱点在于本实验最大输入长度仅为 64，长新闻会从尾部截断；同时，Sports 上的错误明显多于 Bag of Words 和 Word2Vec-NYT，总错误篇数也最多，因此 Accuracy 最低。BERT 的混淆不只集中在政商之间，Sports 与另外两类之间的互相误判也多于 Word2Vec。

对于 Accuracy 和 Macro-F1 排序不一致的情况，测试集 Accuracy 排序为 Binary Bag of Words、Word Frequency、Pre-trained GloVe、Word2Vec-NYT、Word2Vec-AG News、Pre-trained BERT；Macro-F1 前三保持不变，之后变为 Pre-trained BERT、Word2Vec-NYT、Word2Vec-AG News。排序不一致只出现在 BERT 与两个自训 Word2Vec 之间，主要原因是多数类 Sports：BERT 在 Sports 上的错误较多，使 Accuracy 排名靠后；但在少数类 Business 上表现相对较好，使三类等权计算的 Macro-F1 高于 Word2Vec-NYT。因此，这并非 BERT 在三类上的表现全面更好，而是多数类与少数类的分类结果在两个指标中的权重不同。

综上，在这份不平衡的三类新闻数据上，Bag of Words 整体表现最好，适合主题词区分明显、指示词较稳定的栏目分类；Word2Vec 表示维度更低，Pre-trained GloVe 更适合开放领域词汇，自训 Word2Vec 则更依赖与 NYT 数据的领域匹配，但两者共同的弱点是政商类别相近以及平均池化带来的信息损失；Pre-trained BERT 的句向量对少数类和上下文信息的利用更好，但受截断以及 Sports 上额外错误的影响，其 Accuracy 低于 Bag of Words 和静态词向量。

（二）训练过程与学习曲线分析

1. Logistic Regression 学习曲线图

对于 Task1 和 Task2 中以 Logistic Regression 作为分类器的五类方法，绘制了在各自最优正则化参数 C 下、按训练集规模 20%、40%、60%、80% 和 100% 重新训练得到的学习曲线，图中横轴为训练样本量，纵轴为训练集与验证集的 Macro-F1。




图 7: Binary Bag of Words 学习曲线




图 8: Word Frequency 学习曲线

如图7所示, Binary Bag of Words 的训练集 Macro-F1 在各训练规模下均接近 1.0, 验证集 Macro-F1 随样本量增加总体上升, 在约 80% 训练数据处达到最高后略有下降, 训练集与验证集之间始终存在较大间隔。

如图8所示, Word Frequency 的训练集 Macro-F1 在各训练规模下均接近 1.0; 验证集 Macro-F1 总体随样本量上升, 约 40% 处升高、约 60% 处回落, 随后在 80% 和全量上继续提高, 全量时验证集达到最高。




图 9: Pre-trained GloVe 学习曲线




图 10: Word2Vec-AG News 学习曲线

如图9所示, Pre-trained GloVe 的训练集 Macro-F1 随样本量先升后有波动, 整体范围在 0.9575 至 0.9650 之间; 验证集 Macro-F1 随样本量增加先升后在全量处略降, 训练与验证的间隔明显小于 Bag of Words 方法。

如图10所示, Word2Vec-AG News 的训练集 Macro-F1 随样本量变化较为平稳; 验证集 Macro-F1 在约 40% 规模后出现波动, 约 80% 处明显下降, 全量训练时回升。




图 11: Word2Vec-NYT 学习曲线

如图11所示, Word2Vec-NYT 的训练集 Macro-F1 随样本量先升后降再回升, 约 60% 处最高、约 80% 处回落, 整体约在 0.960 至 0.966 之间; 验证集 Macro-F1 总体随样本量上升, 约 40% 与 60% 处接近持平, 约 80% 处略降, 全量时达到最高。

对比五张学习曲线可以看出, Bag of Words 两类方法的训练集 Macro-F1 接近饱和, 与验证集之间的间隔较大; Word2Vec 三类方法的训练集 Macro-F1 未达到饱和, 与验证集之间的间隔相对较小。验证集方面, Binary Bag of Words、Word Frequency 和 Pre-trained GloVe 的 Macro-F1 总体随训练数据量增加而提高, Word2Vec-AG News 波动较大, Word2Vec-NYT 在约 40% 规模后只在较小范围内波动, 全量时验证集最高。五种方法的验证集 Macro-F1 均低于训练集, 增加训练数据并不能消除这一间隔。这说明 Bag of Words 维度很高, 训练集容易几乎完全拟合, 与验证集间隔较大; 而 100 维平均词向量容量有限, 训练集指标难以接近 1.0, 间隔因此更小。增加训练数据有助于验证集提升, 但 Word2Vec-AG News 来自另一语料、波动更大, Word2Vec-NYT 则较早进入小幅波动。

2. 100-dimensional Word2Vec Model 训练损失图

针对 Task2 中的 Word2Vec Trained on AG News、Word2Vec Trained on NYT, 绘制了词向量训练过程中 5 个 epoch 的损失曲线, 横轴是 epoch, 纵轴是 Word2Vec 训练损失。




图 12: Word2Vec-AG News 训练损失曲线




图 13: Word2Vec-NYT 训练损失曲线

如图12和图13所示, 两种语料上的 Word2Vec 训练损失均随 epoch 下降, 前两轮下降较快, 之后仍继续降低, 说明词向量目标在 5 轮内持续优化。在 AG News 上的 Word2Vec 训练损失约从 1.36×10^6 降至 0.77×10^6 , 在 NYT 训练集上的 Word2Vec 训练损失约从 2.04×10^6 降至 1.27×10^6 。

3. Pre-trained BERT 训练曲线图

对于 Task3, 绘制了 Fine-tuning 过程中 3 个 epoch 的训练曲线, 左图横轴是 epoch、纵轴是训练损失, 右图横轴是 epoch、纵轴是验证集 Accuracy 与 Macro-F1。




图 14: Pre-trained BERT 训练曲线

如图14所示, 训练损失随 epoch 持续下降, 约从 0.14 降至 0.01。验证集 Accuracy 与 Macro-F1 在第 2 个 epoch 提升最明显, 此后 Accuracy 基本持平, Macro-F1 在第 3 个 epoch 略有下降。这说明预训练 BERT 模型的 Fine-tuning 过程正常且有效, 训练损失持续下降, 验证集指标在第 2 轮后稳定在较高水平。